

Poder Algorítmico: Auditoria de Viés e Radicalização em Plataformas de Vídeo

Uma Proposta Metodológica de Caixa-Preta no Contexto Brasileiro

Fernanda Soares¹, Gabriel Lacerda¹, Júlia Rocha¹, Yago Garzon¹

¹Pontifícia Universidade Católica de Minas Gerais (PUC Minas)
Curso de Engenharia de Software

{fefesoares16, gabriel.lacerda, yagogarzon, juliarochafiorini}@sga.pucminas.br

Resumo. *Este artigo investiga o conceito de poder algorítmico e sua influência crítica nas dinâmicas democráticas contemporâneas. Através de uma revisão sistemática da literatura e de uma análise técnica aprofundada de estudos empíricos fundamentais, o trabalho identifica a lacuna metodológica central: a dificuldade em isolar o efeito causal do algoritmo do comportamento ativo do usuário, especialmente no contexto sociopolítico brasileiro. Como contribuição principal, propõe-se uma metodologia de auditoria algorítmica externa ("caixa-preta") baseada no uso de agentes automatizados (bots) e na aplicação da métrica de similaridade de Jaccard. O objetivo é isolar e quantificar o viés de recomendação em plataformas de vídeo, estabelecendo as bases para uma investigação empírica rigorosa sobre como o design de sistemas de recomendação pode atuar, de forma autônoma, como infraestrutura de amplificação de desinformação e radicalização.*

Abstract. *This paper investigates the concept of algorithmic power and its critical influence on contemporary democratic dynamics. Through a systematic literature review and a deep technical analysis of empirical studies, we identify the central methodological gap: the difficulty in isolating the causal effect of the algorithm from active user behavior. As a main contribution, we propose an external algorithmic audit methodology (black-box) based on automated agents (bots) and the Jaccard similarity metric. The goal is to isolate and quantify recommendation bias in video platforms, establishing the basis for a rigorous empirical investigation into how recommender system design can autonomously function as an infrastructure for disinformation and radicalization amplification.*

1. Introdução

1.1. Contexto

Nas últimas duas décadas, plataformas digitais, especialmente as de vídeo e mídia social, consolidaram-se como o principal meio de mediação da esfera pública e informacional. Com bilhões de usuários ativos globalmente (o Facebook, por exemplo, conta com cerca de 3 bilhões de usuários ativos mensais e o Google alcança mais de 4 bilhões de usuários diários por meio de buscas e YouTube no mundo), seus sistemas de recomendação operam como poderosos porteiros da atenção, decidindo, em tempo real, o que milhões de

usuários verão. O cerne desse poder reside na sua opacidade (característica de "caixa-preta") e na sua escala global, transformando algoritmos em mecanismos de governança invisível, com impacto direto na formação de opinião e na coesão social.

1.2. Motivação

A importância de estudar o poder algorítmico se tornou evidente em episódios recentes: eleições influenciadas por campanhas de desinformação (como as eleições dos EUA em 2016 e do Brasil em 2022), disseminação de teorias conspiratórias durante a pandemia de COVID-19 (2020-2022) e a crescente polarização política nas redes. Embora diversos estudos já tenham explorado impactos algorítmicos em contextos sociais, eles frequentemente se limitam a análises técnicas ou isoladas, sem integrar plenamente as dimensões sociopolíticas brasileiras e globais. Isso deixa lacunas na compreensão de como algoritmos moldam comportamentos coletivos em sociedades polarizadas, justificando a necessidade de abordagens interdisciplinares que conectem código e cultura. Esses fenômenos mostram que os sistemas de recomendação e classificação das plataformas digitais afetam diretamente a formação de opinião e a confiança nas instituições. Assim, entender como esses mecanismos operam é fundamental para refletir sobre a relação entre tecnologia e democracia, preenchendo essas lacunas e propondo reflexões práticas sobre regulação e ética.

1.3. Problema de Pesquisa

Apesar dos vastos indícios de que os algoritmos de maximização de engajamento favorecem conteúdos polarizadores e extremistas, a literatura enfrenta uma limitação metodológica crucial: a dificuldade em isolar o impacto **causal** do algoritmo da **escolha ativa** do usuário. Estudos baseados em dados internos (*server logs*) carecem de independência, enquanto estudos de rastreamento de usuários apenas apontam correlações. O problema central desta pesquisa é, portanto, desenvolver uma metodologia tecnicamente robusta e independente que possa responder à seguinte questão: *Com que velocidade e intensidade os algoritmos de recomendação conduzem usuários com perfis de vulnerabilidade definidos a conteúdos radicalizados, independentemente da intenção ativa de busca do usuário?*

1.4. Objetivos

Objetivo Geral: Propor e detalhar uma metodologia de auditoria algorítmica externa baseada em bots para isolar e quantificar o viés de radicalização em sistemas de recomendação de plataformas de vídeo.

Objetivos Específicos:

1. Revisar criticamente as metodologias de auditoria existentes (interna e externa) e identificar as lacunas no contexto de radicalização;
2. Definir um protocolo técnico para a criação e estratificação de agentes automatizados (*social bots*) que simulem perfis de vulnerabilidade sociodemográfica;
3. Estruturar o processo de coleta de dados (*logging*) para mapear a árvore de recomendações algorítmicas;
4. Definir e aplicar métricas quantitativas (similaridade de Jaccard e Índice de Radicalização) para mensurar a divergência e a polarização entre diferentes perfis de bots ao longo do tempo.

1.5. Justificativa

A relevância deste projeto reside na sua natureza interdisciplinar e no seu alto impacto potencial. Ao unir a Engenharia de Software (automação e auditoria) com as Ciências Sociais (vulnerabilidade, radicalização), o trabalho propõe uma ferramenta de fiscalização capaz de gerar evidências empíricas inegáveis sobre a responsabilidade do design de sistemas. Tais dados são cruciais para subsidiar o debate regulatório no Brasil, contribuindo para a transparência algorítmica e a proteção da esfera pública contra a manipulação sistêmica. A relevância desta pesquisa está em aproximar duas áreas que raramente dialogam de forma direta: a Computação, que estuda o funcionamento técnico dos algoritmos, e as Ciências Sociais, que analisam seus efeitos culturais e políticos. A proposta é compreender os algoritmos não apenas como código, mas como estruturas de poder que organizam comportamentos e informações em escala global [2, 7], contribuindo para políticas públicas que promovam democracia inclusiva e reduzam polarização.

2. Fundamentação Teórica

O poder das plataformas digitais está na capacidade de organizar fluxos de informação e atenção. Essa força resulta da combinação entre estruturas técnicas (algoritmos de recomendação), modelos econômicos (capitalismo de vigilância) e processos culturais (formação de bolhas informacionais).

2.1. Poder Algorítmico e Capitalismo de Vigilância

Gillespie [7] define os algoritmos como dispositivos de relevância, que decidem o que é visível e invisível, moldando percepções de realidade ao priorizar conteúdo baseado em padrões de engajamento. Esse poder se estende além da tecnologia pura, atuando como uma forma de controle social invisível, conforme Couldry e Mejias [2], que argumentam que algoritmos colonizam a vida humana ao converter interações em dados exploráveis economicamente. No entanto, essa dinâmica é sustentada pelo capitalismo de vigilância, descrito por Zuboff [14], onde plataformas coletam e analisam comportamentos para prever e influenciar ações futuras, monetizando previsões de consumo e interação. Esse modelo cria uma economia da atenção, em que o engajamento do usuário, otimizado para cliques e tempo de uso, se torna o produto central, favorecendo conteúdos polarizadores que reforçam ciclos comportamentais (Figura 1).

2.2. Bolhas Filtrantes e Câmaras de Eco

Pariser [12] introduziu o conceito de bolha filtrante, descrevendo como os algoritmos personalizam o conteúdo e isolam os usuários em zonas informacionais homogêneas. Embora o conceito tenha sido criticado por simplificar as dinâmicas sociais, ele permanece útil para compreender a redução da diversidade de perspectivas e a amplificação da polarização (Figura 2).

2.3. Esfera Pública e Governança Algorítmica

Habermas [9] concebeu a esfera pública como um espaço de deliberação racional e inclusiva. No ambiente digital, essa esfera é reconfigurada por algoritmos que priorizam engajamento em vez de racionalidade. Galloway [6] denomina esse fenômeno de governança por protocolo: normas e regras são embutidas no código, definindo quem pode falar, o que pode ser visto e com que alcance.




Figura 1. Ciclo de feedback da curadoria algorítmica: interações reforçam recomendações e preferências, gerando padrões de comportamento e atenção.




Figura 2. Camadas do sistema do capitalismo de vigilância: os usuários geram dados, as plataformas os processam e as corporações e governos os utilizam para fins econômicos e políticos.

2.4. Democracia Digital e Riscos Contemporâneos

Os efeitos combinados desses fatores apontam para riscos concretos à democracia. Fenômenos como desinformação, manipulação algorítmica e perda de confiança nas instituições ameaçam a deliberação pública e a autonomia dos cidadãos [10, 5]. Compreender o poder algorítmico é, portanto, compreender uma nova forma de poder político que atua não pela coerção, mas pela curadoria da informação e pela gestão invisível da

atenção.

3. Metodologia da Revisão Bibliográfica

Esta seção detalha o protocolo rigoroso utilizado para selecionar as obras fundamentais analisadas neste estudo, garantindo a replicabilidade e a relevância científica do referencial.

3.1. Processo de Coleta e Refino

O levantamento bibliográfico foi conduzido em etapas sequenciais: identificação, triagem, elegibilidade e inclusão, seguindo adaptações do protocolo PRISMA. As buscas foram realizadas nas bases de dados Google Scholar, ACM Digital Library e Scopus, utilizando strings de busca combinando termos como *"algorithmic power"*, *"filter bubbles"*, *"recommender systems"*, *"disinformation"* e *"social bots"*.

O recorte temporal priorizou trabalhos publicados entre 2014 e 2024, visando capturar o estado da arte das plataformas digitais contemporâneas.




Figura 3. Fluxo de Seleção Bibliográfica.

4. Análise Crítica da Literatura e Trabalhos Relacionados

Esta seção classifica os trabalhos selecionados pela metodologia PRISMA e analisa estudos fundamentais sobre o poder algorítmico e a desinformação. A seleção priorizou trabalhos que oferecem dados empíricos robustos e metodologias replicáveis, cujas limitações justificam a abordagem proposta nesta pesquisa.

4.1. Classificação e Mapeamento dos Trabalhos

Para organizar a discussão e conectar a literatura aos objetivos deste projeto, os trabalhos selecionados foram classificados em três eixos temáticos principais que se interceptam, conforme ilustrado na Figura 4:

- (A) Auditoria Técnica e Algorítmica
- (B) Comportamento do Usuário e Psicologia
- (C) Ética e Impacto Democrático




Figura 4. Diagrama de Venn dos Trabalhos Relacionados: Interseção entre Auditoria (A), Comportamento (B) e Ética (C).

4.2. Bakshy, E., Messing, S., and Adamic, L. A. (2015) - Exposure to Ideologically Diverse News and Opinion on Facebook

Bakshy et al. (2015) conduziram um dos maiores estudos quantitativos sobre filtros algorítmicos, utilizando dados internos (*server logs*) de 10,1 milhões de usuários ativos do Facebook nos EUA. A metodologia consistiu em rastrear 7 milhões de URLs distintas compartilhadas entre julho de 2014 e janeiro de 2015, classificadas ideologicamente por um classificador de conteúdo treinado. O estudo mediu a "perda de diversidade" em três

estágios do funil de informação: o conteúdo disponível na rede do usuário, o conteúdo exibido pelo algoritmo e o conteúdo clicado pelo usuário.

Os resultados indicaram que o algoritmo reduz a exposição a conteúdo divergente (*cross-cutting*) em 5% para conservadores e 8% para liberais em comparação com o feed cronológico. No entanto, a escolha individual (viés de clique) reduziu essa exposição em mais 6% a 17% adicionais. A principal limitação metodológica reside no uso de dados **proprietários** sem auditoria externa independente. Nosso trabalho se apropria dessa lacuna para propor uma auditoria "caixa-preta" que independe da colaboração da plataforma, removendo o conflito de interesse inerente à pesquisa corporativa [1].

4.3. Ribeiro, M. H. et al. (2020) - Auditing Radicalization Pathways on YouTube

Diferente da abordagem interna de Bakshy, Ribeiro et al. (2020) adotaram uma metodologia de auditoria externa em larga escala. Os autores coletaram dados de 330.925 vídeos de 349 canais, processando mais de 72 milhões de comentários. A estratégia analítica envolveu a classificação de canais em quatro comunidades (Mídia, Alt-lite, Intellectual Dark Web - IDW, e Alt-right) e o cálculo da similaridade de usuários (*Jaccard similarity*) para rastrear a migração de audiência ao longo do tempo.

O estudo comprovou estatisticamente um "*efeito túnel*": houve uma forte migração de usuários que comentavam inicialmente na IDW e Alt-lite para canais da Alt-right, com uma interseção de base de usuários crescendo consistentemente ano a ano. Embora a metodologia de rastros digitais seja robusta, ela observa apenas a **correlação** de migração, sem isolar o peso da recomendação algorítmica versus a busca ativa do usuário. Nosso projeto busca refinar essa metodologia utilizando "bots" controlados na Fase 1, permitindo isolar a responsabilidade exclusiva do algoritmo de recomendação na sugestão desses caminhos [13].

4.4. Eslami, M. et al. (2015) - "I always assumed that I wasn't really that close to [her]": Reasoning about Invisible Algorithms

Eslami et al. (2015) utilizaram uma metodologia mista (*quali-quantitativa*) focada em Interação Humano-Computador (HCI). O estudo recrutou 40 participantes para entrevistas em profundidade e utilizou uma ferramenta customizada, o *FeedVis*, que comparava lado a lado o *News Feed* curado pelo algoritmo versus o feed completo não filtrado.

Os dados revelaram que 62,5% dos participantes desconheciam completamente a existência da filtragem algorítmica no Facebook. Quando a curadoria foi revelada via *FeedVis*, os usuários expressaram surpresa e reações negativas ("eu achava que ela não postava nada"), seguidas de um aumento na satisfação ao entenderem a lógica do sistema. A limitação deste estudo é a amostra reduzida e o foco na satisfação individual. Nossa pesquisa expande essa abordagem ao tratar a **opacidade algorítmica** não como um problema de usabilidade, mas como um risco democrático que exige auditoria externa [3].

4.5. Mittelstadt, B. D. et al. (2016) - The Ethics of Algorithms: Mapping the Debate

Mittelstadt et al. (2016) realizaram uma revisão sistemática da literatura para construir uma taxonomia dos problemas éticos em algoritmos. O método envolveu o mapeamento conceitual de seis tipos de preocupações, categorizadas em causas epistêmicas (evidência

inconclusiva, inescrutável ou equivocada) e efeitos normativos (resultados injustos e efeitos transformativos).

O estudo conclui que a "*inescrutabilidade*" (opacidade) dos algoritmos torna os métodos tradicionais de responsabilização ética ineficazes, exigindo novas formas de auditoria. Embora fundamental teoricamente, o trabalho carece de validação empírica quantitativa. Nosso trabalho utiliza esse arcabouço teórico para fundamentar as variáveis de nossa auditoria prática, transformando o conceito abstrato de "*efeito transformativo*" em métricas avaliáveis de polarização e radicalização [11].

4.6. Guess, A. et al. (2019) - Less than You Think: Prevalence and Predictors of Fake News Dissemination on Facebook

Guess et al. (2019) aplicaram uma metodologia inovadora ao vincular dados de um painel de *survey* com dados comportamentais reais de compartilhamento no Facebook durante as eleições americanas de 2016. De uma amostra inicial de 3.500 respondentes, cerca de 1.300 consentiram em compartilhar seus dados de perfil, permitindo superar a imprecisão do autorrelato.

Os dados mostraram que o compartilhamento de *fake news* é um evento raro, realizado por menos de 8,5% da amostra. No entanto, o estudo identificou uma forte correlação etária: usuários com mais de 65 anos compartilharam sete vezes mais desinformação do que o grupo mais jovem (18-29 anos), mesmo controlando por ideologia e escolaridade. Essa descoberta quantitativa é crucial para o nosso projeto, pois define o **perfil de "usuário vulnerável"** que utilizaremos na estratificação de nossos bots de pesquisa (Fase 1) para testar se o algoritmo explora especificamente essa vulnerabilidade etária [8].

4.7. Ferrara, E. et al. (2016) - The Rise of Social Bots

Ferrara et al. (2016) desenvolveram uma taxonomia técnica para a detecção de *social bots*. A metodologia do artigo compara a eficácia de sistemas de detecção baseados em grafos (que analisam a estrutura da rede social) versus sistemas baseados em características (*features* de conteúdo, sentimento e padrões temporais).

O estudo demonstra que bots sofisticados conseguem emular padrões temporais humanos (como ritmos circadianos), tornando a detecção baseada apenas em volume de postagem ineficaz, e discute o risco de *astroturfing* (falso apoio popular). A limitação apontada é que as soluções propostas são reativas (detectar o bot após o ataque). Nosso trabalho dialoga com essa limitação ao investigar como a própria arquitetura de recomendação das plataformas pode servir de infraestrutura de amplificação para esses bots, independentemente de sua detecção individual [4].

5. Metodologia Proposta para o Projeto Futuro: Auditoria de Caixa-Preta

Com base nas lacunas identificadas — a necessidade de dados independentes e a separação entre causa algorítmica e correlação de comportamento — propõe-se uma metodologia experimental quantitativa baseada em *social bots* de alto rigor técnico.

5.1. Desenho da Pesquisa

O estudo utilizará um desenho experimental controlado, dividido em três fases (Configuração, Execução e Análise), conforme detalhado na Figura 5. A plataforma alvo

inicial será o YouTube, devido à sua centralidade no debate sobre radicalização.




Figura 5. Metodologia Experimental Proposta: Fases de Configuração, Execução e Análise.

5.2. Detalhamento Técnico das Etapas

5.2.1. Fase 1: Configuração e Criação de Personas (Input)

Serão criados N bots, divididos em 4 grupos (e.g., 10 bots por grupo, totalizando $N = 40$ bots), configurados em um *ambiente sandboxed* limpo (navegadores sem histórico/cookies).

- Implementação de Automação:** O sistema de bots será desenvolvido utilizando uma biblioteca de automação de navegador (e.g., **Python com Selenium** ou **Puppeteer**), operando em modo *headless* (sem interface gráfica) para otimizar o desempenho.
- Estratificação de Perfis e Seed Set:** Os grupos serão definidos com base nos dados de vulnerabilidade: (1) Idoso Conservador, (2) Idoso Progressista, (3) Jovem Conservador, (4) Jovem Progressista. A diferenciação se dará através do *seed set* (conjunto inicial de 5 vídeos). Por exemplo, perfis Conservadores iniciarão com vídeos sobre figuras políticas de direita e mídias associadas; Progressistas com pautas de esquerda e mídias correspondentes.
- Calibração Rigorosa e Validação do Input (Mitigação de Variáveis de Confundimento):** Antes da execução, será realizada uma pré-auditoria para validar a **neutralidade** dos 5 vídeos de inicialização (culinária/ciência) e para garantir

que os *seed sets* polarizadores (Conservador/Progressista) possuam um nível de engajamento (views/likes) e um Score Político inicial equiparável. Isso é crucial para que a divergência observada no Índice de Radicalização possa ser atribuída unicamente à resposta do algoritmo.

4. **Inicialização Neutra:** Todos os bots começarão a navegação a partir de um conjunto idêntico de 5 vídeos de conteúdo neutro, injetados após o *seed set* polarizador. Isso garante que a divergência se inicie puramente a partir da resposta algorítmica ao *seed set*.

5.2.2. Fase 2: Execução e Coleta de Logs (Processamento)

O protocolo de interação foi desenhado para maximizar o sinal algorítmico e minimizar a interferência humana.

1. **Protocolo de Interação e Simulação Comportamental:** O bot executará $T = 10$ iterações por dia durante um período de $D = 5$ dias. Em cada iteração, ele acessará o vídeo mais bem recomendado na seção "Up Next" ou similar, simulando a navegação passiva. Para aumentar o rigor, serão implementados **atrasos randômicos** (*random delays*) e **simulação de movimento do mouse** para mitigar a detecção automática de bots.
2. **Simulação de Watch Time (Variável de Controle):** Para eliminar a variação comportamental do usuário (e.g., pular o vídeo), o bot simulará um tempo de visualização constante e alto ($\sim 90\%$ da duração do vídeo), garantindo que o algoritmo interprete um interesse máximo e reforce o *feedback loop* de recomendação.
3. **Coleta e Estrutura de Logs:** A cada iteração, o script registrará: URL do vídeo consumido, Título, ID do Canal, Posição da Recomendação, e o **Score Político** do vídeo. O log será armazenado em um banco de dados relacional para facilitar a análise temporal.

5.2.3. Fase 3: Análise e Geração de Evidências (Output)

Esta é a fase de mensuração do viés e da radicalização.

1. **Cálculo de Similaridade (Jaccard):** A similaridade entre os conjuntos de vídeos (Logs) recomendados para os diferentes grupos de perfis será calculada diariamente:

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|}$$

Onde A e B são os conjuntos de URLs de vídeos vistos pelos Bots A e B em um dado dia. Uma queda na similaridade de Jaccard ($J \rightarrow 0$) ao longo dos 5 dias indicará a formação e o **isolamento da bolha**.

2. **Mensuração do Índice de Radicalização (Variável Dependente):** O viés será mensurado pelo **aumento no Score Político médio** ($\bar{S}$) do conteúdo recomendado. O **Índice de Radicalização (IR)** será a taxa de crescimento deste score ao longo dos 5 dias para cada perfil, permitindo comparar qual grupo de vulnerabilidade é mais rapidamente conduzido a conteúdos extremistas pelo algoritmo.

5.2.4. Definição Operacional das Variáveis

O rigor científico do projeto depende da clara definição das variáveis:

1. **Score Político (S) e Mitigação de Carga de Trabalho:** O conteúdo de cada vídeo será classificado manualmente por **três codificadores independentes** (para garantir a confiabilidade inter-codificador, com kappa de Cohen $\kappa \geq 0.8$) em uma escala Likert de 5 pontos:
 - (1) Neutro/Acadêmico: Conteúdo factual, noticioso imparcial.
 - (2) Tendencioso: Conteúdo opinativo, mas baseado em fatos verificáveis.
 - (3) Polarizador: Conteúdo que divide explicitamente a audiência, com discurso emocional forte.
 - (4) Desinformação/Viés Extremo: Conteúdo comprovadamente falso ou altamente enviesado e distorcido.
 - (5) Radicalização/Extremismo: Conteúdo que incita ódio, violência ou subversão democrática.

Nota de Viabilidade e Rigor Estatístico: Dado o volume potencial de URLs (milhares de vídeos), a codificação manual censitária é inviável. Será implementada uma estratégia de **amostragem aleatória simples** para cada perfil, calculada para um nível de confiança de 95% e margem de erro de 5% (resultando em um $n \approx 384$ vídeos para análise qualitativa). Esta amostragem garante a validade estatística da ANOVA com uma carga de trabalho gerenciável para a equipe humana.

2. **Análise Estatística:** Para testar a hipótese de que o crescimento do Índice de Radicalização (IR) difere significativamente entre os 4 grupos, será utilizada a **Análise de Variância (ANOVA)** com medidas repetidas (visto que a coleta é temporal, dia 1 ao dia 5), seguida de testes *post-hoc* para identificar quais pares de perfis apresentam a maior divergência. A combinação das métricas será interpretada da seguinte forma: uma queda em Jaccard (isolamento da bolha) *acompanhada por* um aumento significativo do IR demonstrará a **causalidade algorítmica** no processo de radicalização de grupos vulneráveis.

5.3. Aspectos Éticos e de Rigor Técnico

Para manter o rigor e mitigar riscos, serão adotadas as seguintes estratégias:

- **Anonimato e Sandboxing:** Todos os bots operarão em ambientes isolados (**containers ou máquinas virtuais**) e sem ligação com usuários ou redes reais da equipe de pesquisa. Isso representa uma arquitetura robusta para garantir a repetibilidade e isolamento.
- **Prevenção de IP Banimento (Engenharia de Software de Alto Nível):** Será utilizado um serviço de rotação de proxies (VPNs) para garantir que cada bot tenha um IP distinto, prevenindo o banimento e simulando geografias distintas (se necessário). A implementação será feita com **monitoramento contínuo** da taxa de sucesso de requisições, permitindo a substituição ágil de IPs bloqueados, minimizando o risco de interrupção da Fase 2 (Coleta de Logs).
- **Viabilidade Operacional e Custos:** A infraestrutura de coleta foi dimensionada para ser executada em nuvem com baixo custo. Estima-se um orçamento de aproximadamente \$50 USD para a contratação de serviços de *proxies residenciais rotativos* durante a semana de coleta intensiva. O cronograma macro do projeto

prevê: 2 semanas para desenvolvimento dos scripts de automação; 1 semana para pré-auditoria e calibração dos *seed sets*; 1 semana de execução controlada (coleta de dados); e 3 semanas dedicadas à codificação manual da amostra e análise estatística.

- **Justificativa Ética (*Responsible Auditing*):** O uso de bots para violar os Termos de Serviço da plataforma é justificado pelo imperativo público da pesquisa (conforme debatido em [13]) de investigar o impacto sistêmico do poder algorítmico, o qual é inacessível por métodos colaborativos.

6. Considerações Finais

A opacidade dos algoritmos de recomendação representa um risco sistêmico à democracia que exige novas e sofisticadas ferramentas de fiscalização. Este artigo não apenas conceituou o fenômeno do poder algorítmico, mas detalhou uma metodologia de auditoria de caixa-preta baseada em engenharia de software e métricas de polarização, visando isolar o efeito causal do algoritmo no processo de radicalização de grupos vulneráveis.

Referências

- [1] Bakshy, E., Messing, S., & Adamic, L. A. (2015). Exposure to ideologically diverse news and opinion on Facebook. *Science*, 348(6233), 1130-1132.
- [2] Couldry, N., & Mejias, R. L. (2019). *The Costs of Connection: How Data is Colonizing Human Life and Appropriating it for Capitalism*. Stanford University Press.
- [3] Eslami, M., Rosner, D., & Karahalios, K. (2015). "I always assumed that I wasn't really that close to [her]": Reasoning about invisible algorithms in the Facebook news feed. In *Proceedings of the 33rd Annual ACM Conference on Human Factors in Computing Systems* (pp. 153-162).
- [4] Ferrara, E., Varol, O., Davis, C., Menczer, F., & Flammini, A. (2016). The rise of social bots. *Communications of the ACM*, 59(7), 96-104.
- [5] Filgueiras, F. (2021). *Política e Algoritmos: O Capitalismo de Vigilância e a Crise da Democracia*. Companhia das Letras.
- [6] Galloway, A. R. (2006). *Protocol: How Control Exists After Decentralization*. MIT Press.
- [7] Gillespie, T. (2014). The relevance of algorithms. In T. Gillespie, P. Boczkowski, & K. Foot (Eds.), *Media technologies: Essays on communication, materiality and society* (pp. 167-193). MIT Press.
- [8] Guess, A. M., Nagler, J., & Tucker, J. A. (2019). Less than you think: Prevalence and predictors of fake news dissemination on Facebook. *Science Advances*, 5(1).
- [9] Habermas, J. (1984). *The Theory of Communicative Action* (Vol. 1). Beacon Press.
- [10] Han, B. C. (2022). *Infocracy: Digitalization and the Crisis of Democracy*. Polity Press.
- [11] Mittelstadt, B. D., Russell, C., & Wachter, S. (2016). The ethics of algorithms: Mapping the debate. *Science and Engineering Ethics*, 22(5), 1153-1178.
- [12] Pariser, E. (2011). *The Filter Bubble: What the Internet Is Hiding From You*. Penguin Press.

- [13] Ribeiro, M. H., Ottoni, R., Almeida, V. A. F., Benevenuto, F., Mello, P. R., & Zagheni, E. (2020). Auditing radicalization pathways on YouTube. In *Proceedings of the 2020 ACM SIGSAC Conference on Computer and Communications Security* (pp. 1319-1335).
- [14] Zuboff, S. (2019). *The Age of Surveillance Capitalism: The Fight for a Human Future at the New Frontier of Power*. PublicAffairs.